01 结论先看

原图复核改动效果评估

真实监测样本 / 本轮原图、初审框恢复及判定规则组合改动

局部质量改善已有图像证据；
总体准确率是否提升，尚未得到证明。

180	143	4
逐框结果重新核对	原图可定位并目视核查	旧误确认被拦截

本次从测试环境重新读取 **36 个事件**，180 个逐框结论与冻结导出全部一致。未使用既有人工金标评分；图像判断由 Codex 逐项记录，不能替代独立真值。

观察到的变化	数量	业务含义
旧误确认不再自动通过	4	1 个驳回、3 个转人工
原先存疑的清晰车辆改为确认	16	原图存在可辨认车辆依据
当前自动驳回均有非目标图像依据	7	核查未见真目标被误驳回
可辨车辆被支撑面规则转人工	5	其中 3 个此前已自动确认

代价：配对 175 个候选的自动判定覆盖率从 **79.4%** 降至 **68.0%**，人工比例增加 **11.4 个百分点**。误确认拦截增强，同时自动处理能力下降。

适用范围：人员、车辆的已检出候选；当前服务为 v8，但本批持久化结果含 v6/v7/v8。该报告评价已有真实结果，不能称为完整 v8 独立准确率测试。

02 前后统计

更谨慎，但自动处理比例下降

前后比例仅使用有旧结论的 175 个候选；5 个缺少旧结论的候选单列。

指标	历史结果	本轮结果	变化
自动确认	135 / 77.1%	112 / 64.0%	-23
自动驳回	4 / 2.3%	7 / 4.0%	+3
存疑 / 人工	36 / 20.6%	56 / 32.0%	+20
自动判定覆盖率	139/175 = 79.4%	119/175 = 68.0%	-11.4 pp

自动判定覆盖率 =（确认 + 驳回）/ 配对候选数。**该指标不表示准确率。**全量 180 个候选最终为确认 112、驳回 7、人工 61。

逐框迁移矩阵

旧结论 → 新结论	确认	驳回	人工
确认 135	96	1	38
驳回 4	0	4	0
人工 36	16	2	18
缺少旧结论 5（不计配对比例）	0	0	5

38 个“确认 → 人工”不能全部算作纠错：31 个因定位/匹配条件不足；其余 7 个的图像观察分别支持非目标 3、真车 3、身份不清 1。

最终 61 个人工候选的原因

定位/匹配不足	车辆支撑面限制	模型分歧	人员策略限制
37	10	8	6

旧结果中有 12 个事件的汇总计数与逐框 decision 不一致。本报告统一重算逐框结论，未沿用把“存疑”写成“驳回”的历史汇总。

03 图像核查

改善体现在哪里

143 个可定位候选逐项查看原图；37 个定位未通过的候选不强行赋予真/假观察标签。

Codex 原图观察	当前确认	当前驳回	当前人工	合计
支持目标	112	0	7	119
支持非目标	0	7	6	13
不足以判断	0	0	11	11
合计	112	7	24	143

上表是图像核查记录，**不是人工金标或独立盲测**。若干典型案例已在此前调查中见过；当前 119 个自动结论均有图像支持，也不能据此宣称“准确率 100%”。

4 个旧误确认：1 个纠正为假目标，3 个转人工

事件编号（省略 Event-）	框	原图观察	当前结果
20260910084419-2	2	屋顶桌台及座椅	驳回
20260910105113-1	2	屋顶桌台及座椅	人工
20260918104011-2	2	顶部开口固定设施	人工
20260918104011-2	3	红白边界固定设备	人工

其他正向信号：16 个“存疑 → 确认”的候选均可从原图辨认车辆。7 个自动驳回均有非目标依据，但其中 4 个此前已经驳回，只有 3 个是本轮新增驳回。

保留的问题：13 个目视非目标中仍有 6 个需要人工；119 个目视支持目标中有 7 个人工（车辆 5、人员 2）。11 个图像仍不清楚的候选全部人工。

目视依据：车辆外形、车窗/车顶、覆盖车体及停车/道路上下文；非目标依据包括桌椅、固定设备、立柱、树影。低细节或身份不明时记录为“不足以判断”。

04 典型案例

误确认纠正与真车确认

对照图均来自测试环境附件；黄框仅用于页面定位，展示缩放不增加原图细节。

A · 屋顶桌台：确认 → 驳回

Event-20260910084419-2 / 框 2 / v7。原图可见桌面和周围座椅，重复排布于屋顶。旧结果将其确认为车辆，本轮改为假目标。

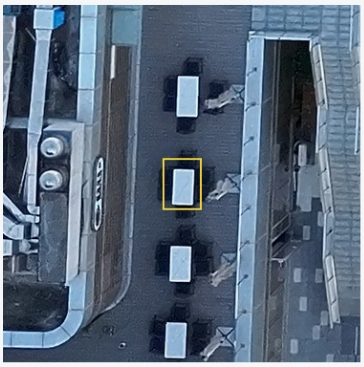
初审标注图 · 对应目标
来源尺寸 4032×3024；展示缩放不增加细节



原图局部 · 保留原始像素内容
来源尺寸 4032×3024；展示缩放不增加细节



原图上下文 · 黄框仅定位
来源尺寸 4032×3024；展示缩放不增加细节



结论：此例支持明确的局部纠错；同时发生了框恢复和模型/规则变化，不能只归因于分辨率。

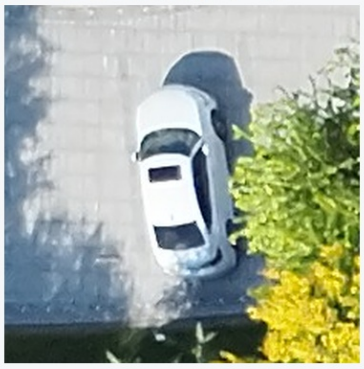
B · 地面白色车辆：存疑 → 确认

Event-20260910084422-2 / 框 1 / v7。初审真实轮廓恢复后，原图显示车身、车窗和天窗，车辆结论有清晰图像依据。

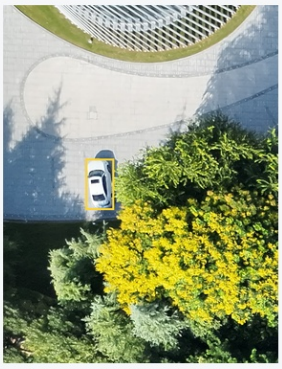
初审标注图 · 对应目标
来源尺寸 4032×3024；展示缩放不增加细节



原图局部 · 保留原始像素内容
来源尺寸 4032×3024；展示缩放不增加细节



原图上下文 · 黄框仅定位
来源尺寸 4032×3024；展示缩放不增加细节



结论：原图加准确定位，使部分可辨真车从存疑进入自动确认；本批共有 16 个类似状态变化。

05 典型案例

高清原图与保守拦截

高清信息增益和策略防护分别陈述，避免把所有变化解释为准确率提升。

C · 广场固定杆件：维持驳回，定位更可靠

Event-20260723105651-5 / 框 1（同事件共 2 框）/ v8。标注图 1440×1080，原图 4032×3024。可见重复排列的杆件和底部结构。

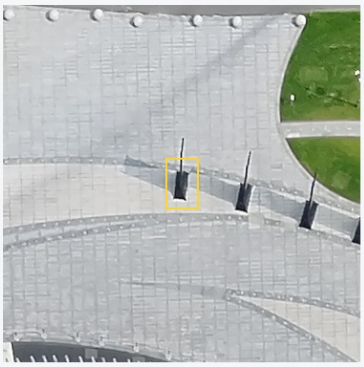
初审标注图 · 对应目标
来源尺寸 1440 × 1080；展示缩放不增加细节



原图局部 · 保留原始像素内容
来源尺寸 4032 × 3024；展示缩放不增加细节



原图上下文 · 黄框仅定位
来源尺寸 4032 × 3024；展示缩放不增加细节



结论：v8 恢复小框后提供可靠原图依据；旧快照已是驳回，因此本例不计为新增准确率收益。

D · 屋顶固定设施：确认 → 人工

Event-20260918104011-2 / 框 2 / v6。原图显示顶部开口的固定设施，缺少车辆特征；支撑面规则阻止自动确认为车辆。

初审标注图 · 对应目标
来源尺寸 4032 × 3024；展示缩放不增加细节



原图局部 · 保留原始像素内容
来源尺寸 4032 × 3024；展示缩放不增加细节



原图上下文 · 黄框仅定位
来源尺寸 4032 × 3024；展示缩放不增加细节



结论：这是拦截自动误确认，尚未自动识别为假目标。该事件框 3 也从确认转为人工。

06 代价与待修正项

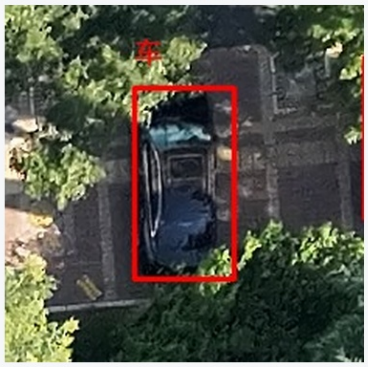
真车也可能被过度拦截

“更少自动通过”不能直接等价为“更准确”；需要同时关注可用性。

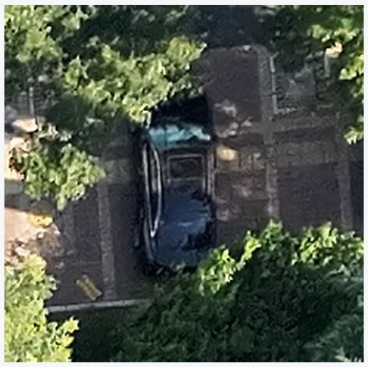
E · 树旁停车：可辨真车，确认 → 人工

Event-20260910084419 / 框 3 / v7。原图可辨车辆，支撑面结果却为 building_roof，因此转人工。类似目视可辨车辆共有 5 个。

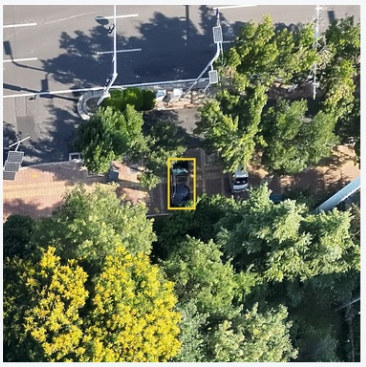
初审标注图 · 对应目标
来源尺寸 4032×3024；展示缩放不增加细节



原图局部 · 保留原始像素内容
来源尺寸 4032×3024；展示缩放不增加细节



原图上下文 · 黄框仅定位
来源尺寸 4032×3024；展示缩放不增加细节



影响：其中 3 个车辆原本已自动确认，现增加人工工作量。优先修正临近建筑、树木的支撑面判断。

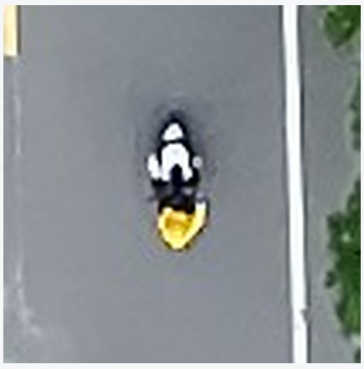
F · 道路骑行者：图像支持人员，仍需人工

Event-20260727151442-4 / 框 1 / v8。原图可见骑行者头部、上身和双臂；人员自动确认开关关闭，最终保持人工。该候选缺少旧结论。

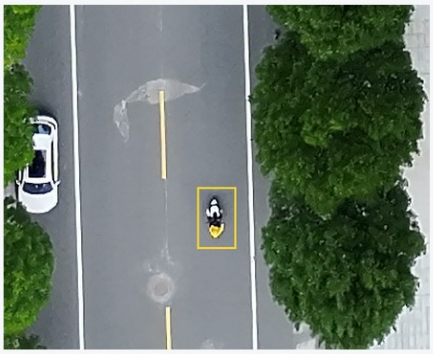
初审标注图 · 对应目标
来源尺寸 1440×1080；展示缩放不增加细节



原图局部 · 保留原始像素内容
来源尺寸 4032×3024；展示缩放不增加细节



原图上下文 · 黄框仅定位
来源尺寸 4032×3024；展示缩放不增加细节



影响：16 个人员候选最终为 0 确认、2 驳回、14 人工；这反映策略限制，不能解释为人员准确率为零。

07 结论边界

为什么还不能给出总体提升百分比

本报告评估真实样本中的可观察改善，不将模型结果转成评价真值。

01 · 前后基线混合

旧基线中 129 个候选的理由为 ResNet、40 个已是 Qwen、6 个为其他理由。新结果也混合 v6/v7/v8，未形成单变量的“有原图/无原图”实验。

02 · 批次不是独立测试集

36 个事件中，17 个与训练事件重合、3 个与验证事件重合；另外 16 个未出现在两者中，也未经独立盲测锁定。相邻帧和重复场景进一步限制统计推广。

03 · 原图覆盖只有一部分

冻结范围 358 个事件中，36 个有可下载且尺寸兼容的关联图对，约 10.1%。其中 35 个事件至少有 1 框原图模型路径生效。其余 322 个事件不能按已验证处理。

04 · 原图不总是更高分辨率

36 对中 33 对像素尺寸相同；3 对原图像素面积为 7.84 倍，但 1 对画面不匹配，实际只有 2 对通过画面一致性检查。去标注和正确定位也可能带来收益。

05 · 缺少独立真值，且人工比例改变

Codex 目视观察未获用户逐条确认；37 个定位受阻候选未做有效定位的真/假判断。人工比例增加会改变自动结论的样本组成，不能据此宣称整体更准确。

> **可确认：局部误确认风险降低。**
> **未证实：总体准确率、全场景召回率和原图的单独因果收益。**

评估对象仅为初审已给出的候选框，无法衡量初审未检出的目标，也不报告全场景 mAP。

08 交付与验收

可复核、可追溯的交付

本次只读取结果、检查图像和运行状态；没有重新训练、发布或改变业务数据。

保存结果版本	事件	候选	说明
v6	22	77	全部可用事件先跑基础改动
v7	11	76	框恢复相关事件继续复核
v8	3	27	小框/合并框相关事件继续复核

当前测试 AI 容器为 clean-source-qwen-20260926-v8，本次只读检查 running / healthy。当前代码沿用已训练 adapter；本轮后续主要改动为定位恢复和策略约束，不是重新训练一个全新模型。

建议按这个顺序验收

1. 先核对 4 个旧误确认、16 个新确认、7 个自动驳回，再查看 5 个被支撑面规则拦下的可辨车辆。
2. 补齐 37 个定位受阻候选的来源与框信息，并改善支撑面判断。
3. 若需正式准确率结论，冻结统一前后版本和新事件批次，先独立看图再核对结果，分别统计误确认、误驳回和人工比例。

证据文件与可复现计算

交付文件	作用
metrics.json / analyze.py	逐框重算、175 配对分母、源文件与旧快照哈希
visual-observations.jsonl	143 个图像核查记录，明确 humanGold=false
live-results.json	2026-09-26 20:04 左右读回；36 事件全部一致
README.md / assets/	完整文字说明、报告使用的初审与原图证据

原始证据：~/Downloads/ktd-clean-source-test-acceptance-20260926/。包括真实样本复核结果、批次汇总、训练重合检查、原图分辨率与来源缺口检查。

180 条源结果 SHA-256：
8c4690b03fe4f510ad8bef85fd7484529a2238d453240aedbb09103e58dc6978

打开测试事件中心 | 打开本机桌台误报对照